



Universidad
Nacional
de Loja

Defensa Metodológica de Proyecto Integrador (Dossier 2)

Evaluación Empírica de Modelos de Predicción en Series Temporales

¿Cómo mejoran las LSTM la predicción en series temporales frente a modelos estadísticos clásicos como ARIMA?

Autor: Yober Edicson Gaona Gaona


Docente Evaluador: Ing. Luis Antonio Chamba Eras

Asignatura: Metodología de la Investigación en Computación (Ciclo 4)

Architectural Decision Flow 16:9




H1: El modelo LSTM reduce significativamente el error de predicción (RMSE y MAE) frente al modelo ARIMA en conjuntos de datos con dependencias de largo plazo y patrones no lineales.



Diseño Experimental y Flujo de Datos (Data Pipeline)

Dataset Público (Series Temporales)

>1000 observaciones,
frecuencia diaria o menor.



Restricción estricta:

Orden cronológico
mantenido intacto.



80% Entrenamiento

20% Prueba

Grupo Experimental (LSTM)

Arquitectura
estándar (1-2
capas ocultas).

Regularización
vía Dropout.

Optimizador
Adam.

Grupo de Control (ARIMA)

Modelo
estadístico
clásico.

Parámetros (p, d, q)
óptimos calibrados
matemáticamente
mediante criterios
AIC/BIC.

Matriz de Escudos (*Risk-Mitigation Table*)

Amenazas a la Validez Interna (Factores de distorsión)

70%



Sobreajuste (Overfitting) - LSTM memoriza los datos de entrenamiento.



Implementación de **Dropout** y validación cruzada temporal.



Configuración de Hiperparámetros - Calibración sesgada que subestime al LSTM.



Búsqueda sistemática y automatizada de parámetros.



Selección de Dataset Sesgado - Usar series estrictamente lineales que favorezcan a ARIMA.



Selección de datasets de no-linealidad demostrada y ampliamente referenciados en literatura.

Amenazas a la Validez Externa (Límites de extrapolación)

30%



Limitada generalización (dominio único).



Replicación del pipeline experimental en al menos dos dominios distintos (ej. métricas de finanzas vs. datos de tráfico vehicular).

Takeaway

La implementación de este experimento controlado aísla la complejidad del entorno y permite dictaminar, mediante causalidad cuantitativa y matemáticamente verificable, si la arquitectura recurrente (LSTM) supera la frontera de precisión del estándar clásico (ARIMA).

Viabilidad Técnica - Herramientas




Lenguaje Base:
Python 3.x



Framework Experimental (LSTM): TensorFlow / Keras



Framework de Control (ARIMA): statsmodels



Ingeniería de Datos y Métricas: pandas, NumPy, scikit-learn