

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Redes de Memoria a Largo Corto Plazo (LSTM)	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	5
1.3.	Metodología y Análisis de la Literatura	6
1.4.	Conclusiones	9

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Redes de Memoria a Largo Corto Plazo (LSTM) para la Predicción y Análisis de Series Temporales.

Autor: Yober Edicson Gaona Gaona (yober.gaona@unl.edu.ec)
Técnica asignada: LSTM

1.1. Introducción

Este capítulo aborda formalmente el uso de las redes de memoria a largo corto plazo (LSTM) para dar respuesta a la pregunta de investigación planteada: ¿Cómo mejoran las LSTM la predicción en series temporales? El análisis de series temporales consiste en extraer información útil de registros históricos para determinar valores futuros, un proceso fundamental en áreas como las finanzas, la meteorología y el transporte [1–3]. Tradicionalmente, este campo ha dependido de modelos estadísticos como el Autorregresivo Integrado de Media Móvil (ARIMA), los cuales, aunque precisos en condiciones de estacionariedad, enfrentan limitaciones críticas para capturar relaciones no lineales complejas o procesos que cambian rápidamente [4–7]. Dentro de los enfoques estocásticos de carácter convencional, coexisten herramientas como el modelo autorregresivo de media móvil univariante (ARMA) —el cual combina dinámicas puramente autorregresivas (AR) con medias móviles (MA)—, así como ramificaciones de carácter multivariante y vectores autorregresivos (VAR) que extienden el análisis al permitir la evolución simultánea de múltiples variables entrelazadas.

A pesar de que el modelo ARIMA ha demostrado históricamente un alto rendimiento y precisión al predecir los rezagos inmediatos de una serie de tiempo, posee restricciones críticas debido a que asume una varianza constante y una estructura intrínsecamente lineal. Estas características limitan severamente su desempeño ante la volatilidad de los mercados financieros modernos o ante escenarios con información incompleta, donde las arquitecturas de aprendizaje profundo consiguen modelar los patrones mediante relaciones contenidas en jerarquías profundas de capas.

A diferencia de las Redes Neuronales Recurrentes (RNN) convencionales, que sufren el problema de la desaparición o explosión del gradiente —lo que les impide aprender dependencias de

largo alcance—, la arquitectura LSTM fue diseñada específicamente para mitigar estas deficiencias [8–11]. La mejora fundamental radica en la introducción de la Unidad de Error Constante (CEC) y un sofisticado mecanismo de puertas (entrada, salida y olvido) que regula el flujo de información dentro de una celda de memoria [12, 13]. Estas puertas permiten al modelo decidir selectivamente qué información histórica descartar y qué datos nuevos son relevantes para la predicción, logrando conectar eventos con desfases temporales de más de 1,000 pasos [14, 15].

En las RNN estándar, la evolución temporal de las señales de error mapeadas hacia atrás en el tiempo depende de manera exponencial de la magnitud de los pesos sinápticos, provocando que los gradientes retropropagados se desvanezcan o exploten con rapidez. Esto restringe la capacidad de aprendizaje de las RNN tradicionales a ventanas de tiempo cortas, de apenas 5 a 10 pasos discretos entre eventos de entrada y señales objetivo. El carrusel de error constante (CEC) de la LSTM solventa este problema al asegurar un flujo de error constante a través de sus unidades autorrecurrentes protegidas por compuertas multiplicativas. Sin embargo, la arquitectura clásica de la LSTM experimentaba fallos al procesar flujos de datos continuos y prolongados que no estuvieran segmentados de forma preliminar en subsecuencias con inicios y finales explícitos. Sin un mecanismo de reinicio, el estado interno de las celdas crecía de forma indefinida hasta saturar los recursos y causar el colapso de la red.

La implementación de la "puerta de olvido" (forget gate) aportó un remedio adaptativo que faculta a la celda para aprender a restablecerse autónomamente en momentos idóneos, ya sea de forma rítmica o guiada por las entradas del sistema. Adicionalmente, el desempeño ante desfases temporales prolongados se potencia mediante el uso de celdas LSTM dotadas con conexiones de mirilla ("peephole connections"), las cuales facilitan que las compuertas inspeccionen directamente sus propios estados internos actuales para computar y medir con alta precisión intervalos de tiempo en tareas de alta complejidad no lineal.

La superioridad de las LSTM se manifiesta en su capacidad para modelar estructuras intrínsecas en datos de alta dimensionalidad y ruido [16, 17]. Estudios empíricos demuestran que, en comparativas directas contra modelos ARIMA en series financieras y económicas, las LSTM pueden reducir las tasas de error (RMSE) en un rango de entre el 84 y 87 por ciento. Además, la arquitectura estándar ha evolucionado hacia variantes avanzadas como las LSTM Bidireccionales (BiLSTM), que procesan la secuencia en ambas direcciones para capturar un contexto temporal completo [18, 19], y la integración de mecanismos de atención, que permiten a la red enfocarse dinámicamente en los puntos más críticos de la historia temporal para optimizar la precisión [20, 21].

En análisis empíricos profundos, se ha determinado que las redes BiLSTM logran consistentemente mejores resultados de predicción en contraste con las celdas individuales y las arquitecturas apiladas ("stacked") de múltiples capas ocultas. Este rendimiento sobresaliente se mantiene estable tanto al evaluar diferentes categorías de series temporales (tales como variables macroeconómicas o demográficas) como al someterlas a distintos horizontes de pronóstico, consolidando errores porcentuales absolutos medios (MAPE) inferiores al 18 por ciento. De forma paralela, el análisis del proceso de optimización matemática de estas redes arroja un hallazgo singular: el incremento del número de iteraciones de entrenamiento —conocidas como épocas en el ámbito del aprendizaje profundo— no ejerce una influencia directa ni predecible sobre la precisión final del pronóstico, manifestando un ajuste con fluctuaciones puramente aleatorias.

La necesidad de modelos más avanzados surge porque los métodos tradicionales, como el modelo Autorregresivo Integrado de Media Móvil (ARIMA), se basan en supuestos de linealidad y a menudo requieren que las series sean estacionarias, lo que limita su capacidad para modelar procesos caóticos o ruidosos [4, 5]. Mientras que ARIMA tiende a concentrarse en los valores

medios de los datos históricos, las redes LSTM destacan por su flexibilidad para identificar estructuras intrínsecas en datos de alta dimensionalidad [1,4]. Esta capacidad es fundamental en dominios donde los patrones no se repiten de forma idéntica, permitiendo a las LSTM capturar la no linealidad y la aleatoriedad inherentes a fenómenos como el tráfico vehicular o las fluctuaciones bursátiles [12,14].

Para que modelos estadísticos como ARIMA puedan operar de forma correcta, la serie temporal bajo estudio debe ser estrictamente estacionaria (con media y varianza estables), lo que obliga a ejecutar transformaciones obligatorias en la etapa de preprocesamiento de datos, recurriendo a procesos de diferenciación matemática para eliminar componentes de tendencia y estacionalidad. Por el contrario, los modelos basados en redes LSTM poseen la cualidad de alimentarse de manera directa con las secuencias de valores observados crudos para estimar los estados futuros, eximiendo al investigador de aplicar preprocesamientos forzados para estacionarizar la serie. Esta virtud operativa de trabajar con señales en bruto es crucial en campos de alta complejidad científica, tales como la monitorización y análisis de series temporales médicas continuas extraídas de electrocardiogramas (ECG). Las metodologías tradicionales de procesamiento biomédico demandan un preprocesamiento extenso para construir manualmente vectores de características en el dominio del tiempo-frecuencia (como el uso de coeficientes de ondículas) y dependen de bases de datos exhaustivamente etiquetadas con todas las variaciones patológicas y tipos de arritmias existentes para poder entrenar clasificadores eficientes. En contraposición, las arquitecturas deep LSTM analizan la señal biomédica cruda sin procesamientos elaborados y, al entrenarse exclusivamente con datos procedentes de ritmos cardíacos sanos, configuran un modelo predictivo que identifica anomalías o arritmias desconocidas basándose únicamente en la distribución de probabilidad de los errores de predicción generados por la propia red neural [15,17].

1.2. Fundamentos Teóricos

La arquitectura Long Short-Term Memory (LSTM) constituye una clase especializada de red neuronal recurrente (RNN) diseñada específicamente para mitigar las patologías de la desaparición y explosión del gradiente asociadas al algoritmo de retropropagación a través del tiempo (BPTT) [6,15,16,22,23]. A diferencia de las RNN convencionales, cuyas unidades ocultas computan transformaciones no lineales simples, la LSTM introduce el concepto de bloque de memoria.

Este bloque integra una unidad central denominada Carrusel de Error Constante (CEC), la cual permite que el error fluya de manera persistente y sin degradación a lo largo de intervalos temporales extensos, facilitando el aprendizaje de dependencias que superan los 1,000 pasos de tiempo [2,3,14].

El procesamiento de una secuencia temporal $\mathbf{X} = \{x_1, x_2, \dots, x_t\}$ dentro de una celda LSTM se rige por un sistema de compuertas multiplicativas que regulan de forma adaptativa el flujo de información [1,4,6,13]. Estas compuertas (olvido, entrada y salida) actúan como interruptores analógicos que deciden, respectivamente, qué información histórica debe ser eliminada para evitar la saturación, qué nuevos estímulos estructurales deben integrarse al estado de la celda y qué parte de la memoria interna debe proyectarse hacia el estado oculto para la generación de predicciones [15,19,23].

Formalmente, la dinámica interna de una unidad LSTM en el instante t se define mediante el siguiente conjunto de transformaciones afines seguidas de activaciones no lineales expresada

formalmente en la Ecuación. 1.1:

$$\mathbf{X} = \{x_1, x_2, \dots, x_t\} \quad (1.1)$$

A partir de dicha secuencia $\mathbf{X}$, el flujo secuencial e interno de la celda de la red se rige por el sistema de operaciones detallado en la Ecuación 1.2:

$$\begin{cases} f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) & \text{(Compuerta de Olvido)} \\ i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) & \text{(Compuerta de Entrada)} \\ \tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) & \text{(Candidato a Estado de Celda)} \\ \mathbf{c}_t = \mathbf{f}_t \circ \mathbf{c}_{t-1} + \mathbf{i}_t \circ \tilde{\mathbf{c}}_t & \text{(Actualización del Estado de Celda)} \\ o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) & \text{(Compuerta de Salida)} \\ h_t = o_t \circ \tanh(\mathbf{c}_t) & \text{(Estado Oculto / Salida)} \end{cases} \quad (1.2)$$

Donde:

- σ denota la función de activación logística sigmoide, la cual comprime las señales en el intervalo (0,1), permitiendo que las compuertas actúen como interruptores suaves [1, 23].
- $\circ$ representa el producto de Hadamard (elemento a elemento), el cual garantiza una interacción lineal en la actualización de la memoria, evitando las distorsiones no lineales que causan la inestabilidad del gradiente [22, 23].
- La compuerta de olvido (f_t) decide qué proporción de la memoria anterior (c_{t-1}) se conserva. Si ($f_t = 0$), la red "olvida" el pasado; si ($f_t = 1$), la memoria fluye sin cambios a través del CEC [1, 6, 24], es fundamental para el análisis de flujos continuos de datos, ya que permite a la red resetear memorias obsoletas y liberar recursos computacionales de forma autónoma [3, 4].
- La compuerta de Entrada (i_t) modula qué nuevos patrones estructurales (x_t) son lo suficientemente relevantes para ser almacenados [1, 6, 23].
- El carrusel de Error Constante (CEC) el término ($c_t = f_t o c_{t-1} + 1 + \dots$) permite que el error retropropagado no se multiplique por pesos que lo atenúen exponencialmente, garantizando un aprendizaje robusto en secuencias de larga duración [2, 6].
- El estado de la celda (c_t) actúa como una "línea de memoria" de alta fidelidad que atraviesa la cadena de módulos recurrentes, mientras que el estado oculto (h_t) constituye la interpretación filtrada de dicha memoria para la tarea de predicción específica [4, 5].

Esta arquitectura posee una complejidad computacional de actualización de $O(1)$ por peso y paso temporal, lo que la hace localmente eficiente en espacio y tiempo, permitiendo su despliegue en sistemas de alta dimensionalidad como mercados financieros y redes de tráfico vehicular [2].

1.3. Metodología y Análisis de la Literatura

El proceso metodológico que fundamenta la elaboración de este capítulo se basó en una revisión sistemática y crítica de literatura científica indexada en bases de datos de alto impacto como Scopus y Web of Science. El criterio de selección se estructuró bajo una jerarquización

científica que priorizó, en primer lugar, los trabajos seminales de Hochreiter y Schmidhuber que definieron el paradigma de las celdas de memoria [2, 4]; en segundo lugar, las innovaciones arquitectónicas que introdujeron el mecanismo de "puerta de olvido" para el manejo de flujos de datos continuos [3]; y finalmente, estudios empíricos contemporáneos que validan la superioridad de las LSTM frente a métodos econométricos clásicos y otras variantes de aprendizaje profundo en entornos de alta volatilidad [1, 25, 26]. Para identificar las dimensiones de rendimiento técnico clave, se analizaron comparativas de error cuadrático medio (RMSE) y precisión predictiva en diversos dominios, desde las finanzas y el tráfico vehicular hasta la meteorología y el diagnóstico médico, permitiendo extraer un diagnóstico exhaustivo de las capacidades y limitaciones estructurales de estas redes al enfrentar problemas de secuenciación y forecasting [1, 7, 19]. A continuación, se analizan en detalle las dimensiones técnicas identificadas que definen la operatividad de las LSTM en el análisis de series temporales:

1. Dependencia Temporal y Retención de Memoria.

La ventaja tecnológica primordial de la LSTM es su capacidad para capturar dependencias de largo alcance, superando la restricción de los 5 a 10 pasos temporales de las RNN convencionales para alcanzar horizontes de más de 1,000 pasos [2, 3, 14]. Esto se logra mediante el Carrusel de Error Constante (CEC) y el sistema de compuertas multiplicativas (entrada, salida y olvido) que regulan el flujo de información dentro de la celda [2, 4, 27]. La compuerta de olvido es especialmente crítica, ya que permite al sistema resetear.^o atenuar de forma adaptativa la información histórica que ha dejado de ser relevante, evitando la saturación del estado de la celda y mitigando de raíz el problema del desvanecimiento del gradiente [3, 23]. No obstante, existe una restricción intrínseca: a pesar de su robustez, estas redes presentan dificultades para realizar un conteo preciso de pasos temporales en secuencias extremadamente extensas, lo que a menudo requiere la integración de mecanismos de atención para enfocar el modelo en puntos críticos de la historia temporal [2, 24].

2. Capacidad Predictiva y Modelado No Lineal.

Las redes LSTM destacan por su flexibilidad para modelar dinámicas no lineales complejas y patrones estocásticos en datos de alta dimensionalidad, superando los supuestos de linealidad y estacionariedad que limitan a modelos como ARIMA [1, 17]. Diversos estudios demuestran que las LSTM pueden reducir las tasas de error en un rango de entre el 84 y el 87 por ciento frente a modelos estadísticos tradicionales en series financieras y económicas [1]. Sin embargo, esta elevada capacidad de representación conlleva un riesgo latente de sobreajuste (overfitting), particularmente cuando se trabaja con conjuntos de datos ruidosos o limitados [19]. Para contrarrestar esta vulnerabilidad, es imperativo aplicar técnicas rigurosas de regularización como el dropout en las conexiones no recurrentes y realizar una optimización de hiperparámetros sistemática mediante búsqueda bayesiana o evolutiva [28].

3. Costo Computacional y Eficiencia de Procesamiento

Desde una perspectiva operativa, las LSTM ofrecen una complejidad de actualización eficiente de $O(1)$ por peso y paso temporal, lo que garantiza un procesamiento constante de los vectores de entrada independientemente de la longitud de la secuencia en términos de almacenamiento [2, 3]. Sin embargo, su arquitectura basada en la recursividad impone una restricción de paralelización: a diferencia de los modelos basados en Transformers o mecanismos de atención pura, las LSTM deben procesar la información de manera secuencial, lo que limita el aprovechamiento de infraestructuras de cómputo masivamente paralelo durante el entrenamiento [21, 29]. A pesar de esto, las LSTM siguen siendo la opción preferida en escenarios con datos escasos o recursos limitados, donde su sesgo inductivo secuencial

permite una convergencia más estable y un despliegue más ágil en dispositivos de borde (edge computing) en comparación con arquitecturas más pesadas [19].

A partir de la evaluación crítica de la literatura seleccionada, se desprende que la arquitectura LSTM no constituye únicamente una mejora incremental sobre sus predecesores, sino una redefinición del procesamiento secuencial que aborda de raíz la inestabilidad de los gradientes mediante la implementación del Carrusel de Error Constante (CEC) [3, 14]. Esta capacidad técnica permite integrar información estructural remota en el tiempo, superando con creces los horizontes de memoria de las RNN convencionales y permitiendo capturar dinámicas no lineales en fenómenos complejos que van desde la carga eléctrica residencial hasta la producción de gas natural [6, 12].

La evidencia empírica acumulada en múltiples dominios subraya una superioridad predictiva robusta, reportando reducciones de error (RMSE) de hasta el 87 por ciento frente a métodos estadísticos tradicionales como ARIMA, aunque su despliegue operativo exige una gestión rigurosa del sobreajuste y del costo computacional asociado a su flujo intrínsecamente secuencial [1, 19]. En este sentido, la sistematización de estos hallazgos permite configurar un diagnóstico balanceado sobre las capacidades de estas redes, el cual se sintetiza técnica y comparativamente en la tabla que se presenta a continuación en la Tabla 1.1

Tabla 1.1: Síntesis de Dimensiones Operativas de las Redes LSTM en Series Temporales

Parámetro	Ventaja Tecnológica	Restricción
Dependencia Temporal	Captura de dependencias de largo alcance ($>1,000$ pasos) mediante el Carrusel de Error Constante (CEC) [1–3].	Dificultad para realizar conteos discretos de tiempo precisos en secuencias extremadamente largas [4].
Capacidad Predictiva	Modelado de dinámicas no lineales complejas con reducciones de error de hasta el 87% frente a modelos ARIMA [5–8].	Elevada susceptibilidad al sobreajuste (<i>overfitting</i>) cuando se opera con datos ruidosos o limitados [9–11].
Costo Computacional	Complejidad de actualización eficiente de $O(1)$ por peso y paso temporal; arquitectura local en espacio y tiempo [1, 12, 13].	La naturaleza recursiva impide la paralelización masiva del entrenamiento en comparación con los <i>Transformers</i> [14–16].

1.4. Conclusiones

- Resolución de patologías de entrenamiento en redes recurrentes: La principal mejora de las LSTM frente a las RNN convencionales es su capacidad para mitigar de manera efectiva los problemas de desvanecimiento y explosión del gradiente [6, 16, 20]. Mediante la implementación del Carrusel de Error Constante (CEC), la arquitectura garantiza un flujo de error estable, permitiendo que el modelo aprenda dependencias temporales que superan los 1,000 pasos de tiempo, una capacidad que los modelos previos no podían alcanzar [2, 3, 14].
- Gestión selectiva de la memoria mediante el mecanismo de compuertas: A diferencia de los modelos estadísticos que procesan la información de manera uniforme, las LSTM introducen un sistema de compuertas multiplicativas (entrada, salida y olvido) que regulan el flujo de datos [4, 6, 13]. La inclusión de la compuerta de olvido es fundamental, ya que permite al sistema descartar información histórica irrelevante o ruidosa de forma adaptativa, evitando la saturación del estado de la celda y optimizando la precisión en predicciones de largo plazo [3, 27].
- Superioridad empírica frente a métodos econométricos tradicionales: La evidencia analizada demuestra que las LSTM superan significativamente a modelos clásicos como ARIMA, especialmente en entornos de alta volatilidad y no linealidad [1, 20]. En estudios comparativos sobre series financieras y económicas, el uso de LSTM ha reportado reducciones en las tasas de error (RMSE) de entre el 84 y el 87 por ciento [1]. Esto se debe a su capacidad intrínseca para identificar estructuras complejas en datos de alta dimensionalidad sin requerir supuestos estrictos de estacionariedad [1, 5, 16].
- Eficacia en el modelado de dinámicas no lineales complejas: Las LSTM mejoran la predicción al actuar como aproximadores universales capaces de capturar patrones no lineales intrincados en diversas disciplinas, desde la carga eléctrica residencial hasta el diagnóstico médico multietiqueta [5, 20, 30]. Su capacidad para asociar memorias remotas con entradas actuales permite que el modelo se adapte dinámicamente a cambios bruscos en la tendencia de la serie, superando a métodos de aprendizaje automático "sin memoria" como los bosques aleatorios [17, 22].
- Evolución hacia arquitecturas híbridas y contextuales: El rendimiento de las LSTM se ha potenciado mediante variantes como las LSTM Bidireccionales (BiLSTM), que procesan la información en ambos sentidos del tiempo para capturar un contexto completo [5, 6, 19, 31]. Asimismo, la integración de mecanismos de atención ha permitido a estas redes enfocarse dinámicamente en los puntos temporales más críticos, mitigando la sobrecarga de información en secuencias extremadamente largas y mejorando la interpretabilidad en dominios sensibles como la medicina y la energía [7, 19, 23].
- Limitaciones operativas y consideraciones de diseño: A pesar de su robustez, las LSTM enfrentan desafíos relacionados con su elevado costo computacional y la imposibilidad de paralelización intrínseca debido a su naturaleza secuencial [21, 27, 32]. Además, el riesgo de sobreajuste (overfitting) en conjuntos de datos limitados exige el uso riguroso de técnicas de regularización como el dropout y una optimización cuidadosa de hiperparámetros para garantizar la generalización del modelo en entornos del mundo real [16, 26, 30].
- A diferencia de los modelos estadísticos tradicionales que requieren series temporales completas y uniformes, las redes LSTM demuestran una robustez excepcional para procesar secuencias de longitud variable y mediciones con muestreos irregulares [6, 33]. Esta capacidad técnica permite al modelo aprender directamente de señales crudas incluso en

presencia de datos faltantes o ruidos significativos, lo cual es fundamental en dominios críticos como la medicina intensiva, donde los registros clínicos no son equidistantes, o en la teledetección satelital, donde las nubes pueden contaminar las series de imágenes [4, 6, 33].

- La arquitectura LSTM actúa como un componente modular versátil que permite la construcción de modelos spatiotemporales complejos al combinarse con otras redes, como las CNN para la extracción de características espaciales o mecanismos de atención para jerarquizar información [31, 32]. Esta sinergia permite a las LSTM no solo procesar valores numéricos, sino integrar fuentes de datos de distinta naturaleza —como imágenes satelitales, variables climáticas y topográficas— para generar predicciones holísticas en fenómenos multidimensionales como la agricultura de precisión o el desplazamiento de laderas [31, 34].

Referencias

- [1] S. Siامي-Namini, N. Tavakoli, and A. S. Namin, “International conference on machine learning and applications,” in *A Comparison of ARIMA and LSTM in Forecasting Time Series*, 2018.
- [2] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, 2025.
- [3] F. A. Gers, J. Schmidhuber, and F. Cummins, “Learning to forget: Continual prediction with lstm,” *Neural Computation*, vol. 12, no. 10, 2020.
- [4] Y. Hua, Z. Zhao, R. Li, X. Chen, Z. Liu, and H. Zhang, “Deep learning with long short-term memory for time series prediction,” *IEEE Communications Magazine*, vol. 57, no. 6, 2019.
- [5] N. Q. Dung, P. N. Minh, and I. Zelinka, “Forecasting time series with long short-term memory networks,” *Can Tho University Journal of Science*, vol. 12, no. 2, 2020.
- [6] Z. Cui, R. Ke, Z. Pu, and Y. Wang, *Stacked Bidirectional and Unidirectional LSTM Recurrent Neural Network for Network-wide Traffic Speed Prediction*. University of Washington, 2018.
- [7] J. Ju and F.-A. Liu, “Multivariate time series data prediction based on att-lstm network,” *Applied Sciences*, vol. 11, no. 20, 2021.
- [8] Y. Ma, T. Ji, G. Yang, Y. Chen, W. Xu, , and H. Liu, “Time series prediction based on lstm,” *IEEE Access*, vol. 10, 2022.
- [9] W. Bao, J. Yue, and Y. Rao, “A deep learning framework for financial time series using stacked autoencoders and longshort term memory,” *PLOS ONE*, vol. 12, no. 7, 2017.
- [10] S. Elsworth and S. Guttel, *Time Series Forecasting Using LSTM Networks: A Symbolic Approach*. arXiv preprint, 2020.
- [11] D. C. Han, “Prediction of traffic volume based on deep learning model for aadt correction,” *MDPI*, 2024.
- [12] Y. Tian and L. Pan, “Predicting short-term traffic flow by long short-term memory recurrent neural network,” in *International Conference on Smart City/SocialCom*, 2015.
- [13] N. H. A. Rahman, S. I. Sulaiman, M. A. Hairuddin, M. Z. Hussin, and E. H. M. Saat, “Sliding window-based deep learning approach for solar power forecasting in malaysia utility-scale pv systems,” *Sliding Window-Based Deep Learning Approach for Solar Power Forecasting in Malaysia Utility-Scale PV Systems*, vol. 21, no. 1, 2026.
- [14] K. Albeladi, B. Zafar, and A. Mueen, “Time series forecasting using lstm and arima,” *International Journal of Advanced Computer Science and Applications*, vol. 14, no. 1, 2023.

- [15] S. Chauhan and L. Vig, *Anomaly Detection in ECG Time signals via Deep Long Short-Term Memory Networks*. Jawaharlal Nehru University, 2015.
- [16] Y.-L. Kong, Q. Huang, C. Wang, J. Chen, J. Chen, and D. He, “Long short-term memory neural networks for online disturbance detection in satellite image time series,” *MDPI*, 2018.
- [17] K. Chen, Y. Zhou, and F. Dai, “A lstm-based method for stock returns prediction : A case study of china stock market,” in *IEEE International Conference on Big Data*, 2015.
- [18] K. Bai, S. Jin, Z. Zhang, and S. Dai, “Drilling rate of penetration prediction based on cbt-lstm neural network,” *Sensors*, 2024.
- [19] M. Krichen and A. Mihoub, “Long short-term memory networks: A comprehensive survey,” *MDPI*, 2025.
- [20] X. WEN and W. LI, “Time series prediction based on lstm-attention-lstm model,” *IEEE Access*, vol. 11, 2023.
- [21] R. P. Varshney and D. K. Sharma, “A multi-modal image encoding and self-attention-based transformer framework with sentiment analysis for financial time series prediction,” *Inderscience Publishers*, 2024.
- [22] T. Fischer and C. Krauss, “Deep learning with long short-term memory networks for financial market predictions,” *European Journal of Operational Research*, vol. 270, no. 2, 2018.
- [23] M. Kilinc, “Lstm-based time series forecasting of user-derived quality signals in mobile banking systems,” *Systems*, vol. 13, no. 949, 2025.
- [24] Z. C. Lipton, D. C. Kale, C. Elkan, and RandallWetzel, “Learning to diagnose with LSTM recurrent neural networks,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, (San Juan, Puerto Rico), 2016.
- [25] A. Boudette and H. Al-Anbaki, “Long short-term memory neural networks for one-step time series forecasting,” *Information Sciences*, vol. 562, 2021.
- [26] S. Smyl, “A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting,” *International Journal of Forecasting*, vol. 36, no. 1, 2020.
- [27] F. Kratzert, D. Klotz, C. Brenner, K. Schulz, and M. Herrnegger, “Rainfall–runoff modelling using long short-term memory (LSTM) networks,” *Hydrology and Earth System Sciences*, vol. 22, no. 11, 2018.
- [28] B. S. Freeman, G. Taylor, B. Gharabaghi, and J. The, “Forecasting air quality time series using deep learning,” *Journal of the Air & Waste Management Association*, vol. 68, no. 8, 2018.
- [29] K. Yang, S. Han, J. Zhang, Y. Dou, and G. Wang, “Distributed interactive simulation dead reckoning based on plo–transformer–lstm,” *Electronics*, vol. 15, no. 596, 2026.
- [30] F. Kratzert¹, D. Klotz¹, C. Brenner, K. Schulz, and M. Herrnegger, “Rainfall–runoff modelling using long short-term memory (lstm) networks,” *Hydrol. Earth Syst. Sci*, vol. 22, 2018.
- [31] M. Li, L. Sun, and Y. Sun, “Long-term and short-term photovoltaic power generation forecasting using a multi-scale fusion mha-bilstm model,” *Energies*, vol. 19, no. 363, 2026.

- [32] J. Geng, C. Luo, J. Lu, D. Kong, X. Li, and H. Liu, “2c-net: A novel spatiotemporal dual-channel network for soil organic matter prediction using multi-temporal remote sensing and environmental covariates,” *Remote Sensing*, vol. 17, no. 3358, 2025.
- [33] A. Gensler, J. Henze, B. Sick, and N. Raabe, “Deep learning for solar power forecasting — an approach using autoencoder and LSTM neural networks,” in *Proceedings of the IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, (Budapest, Hungary), IEEE, 2016.
- [34] P. Latha and P. Kumaresan, “Deep learning model optimization for crop prediction and recommendation using harris hawks optimization,” *Environmental Research Communications*, vol. 7, no. 4, 2025.